

# Sprawozdanie z Projektu „Dno oka”

## 1. Skład grupy

- Adam Detmer 155976
- Jakub Buler 155987

## 2. Zastosowany język programowania i biblioteki

- **Język:** Python
- **Środowisko:** Google Colab / Jupyter Notebook
- **Biblioteki:**
  - numpy, opencv-python, scikit-image – Przetwarzanie obrazu
  - scikit-learn – metryki klasyfikacji, modele ML
  - matplotlib, pandas – wizualizacja i raportowanie
  - torch, torchvision – Sieci neuronowe

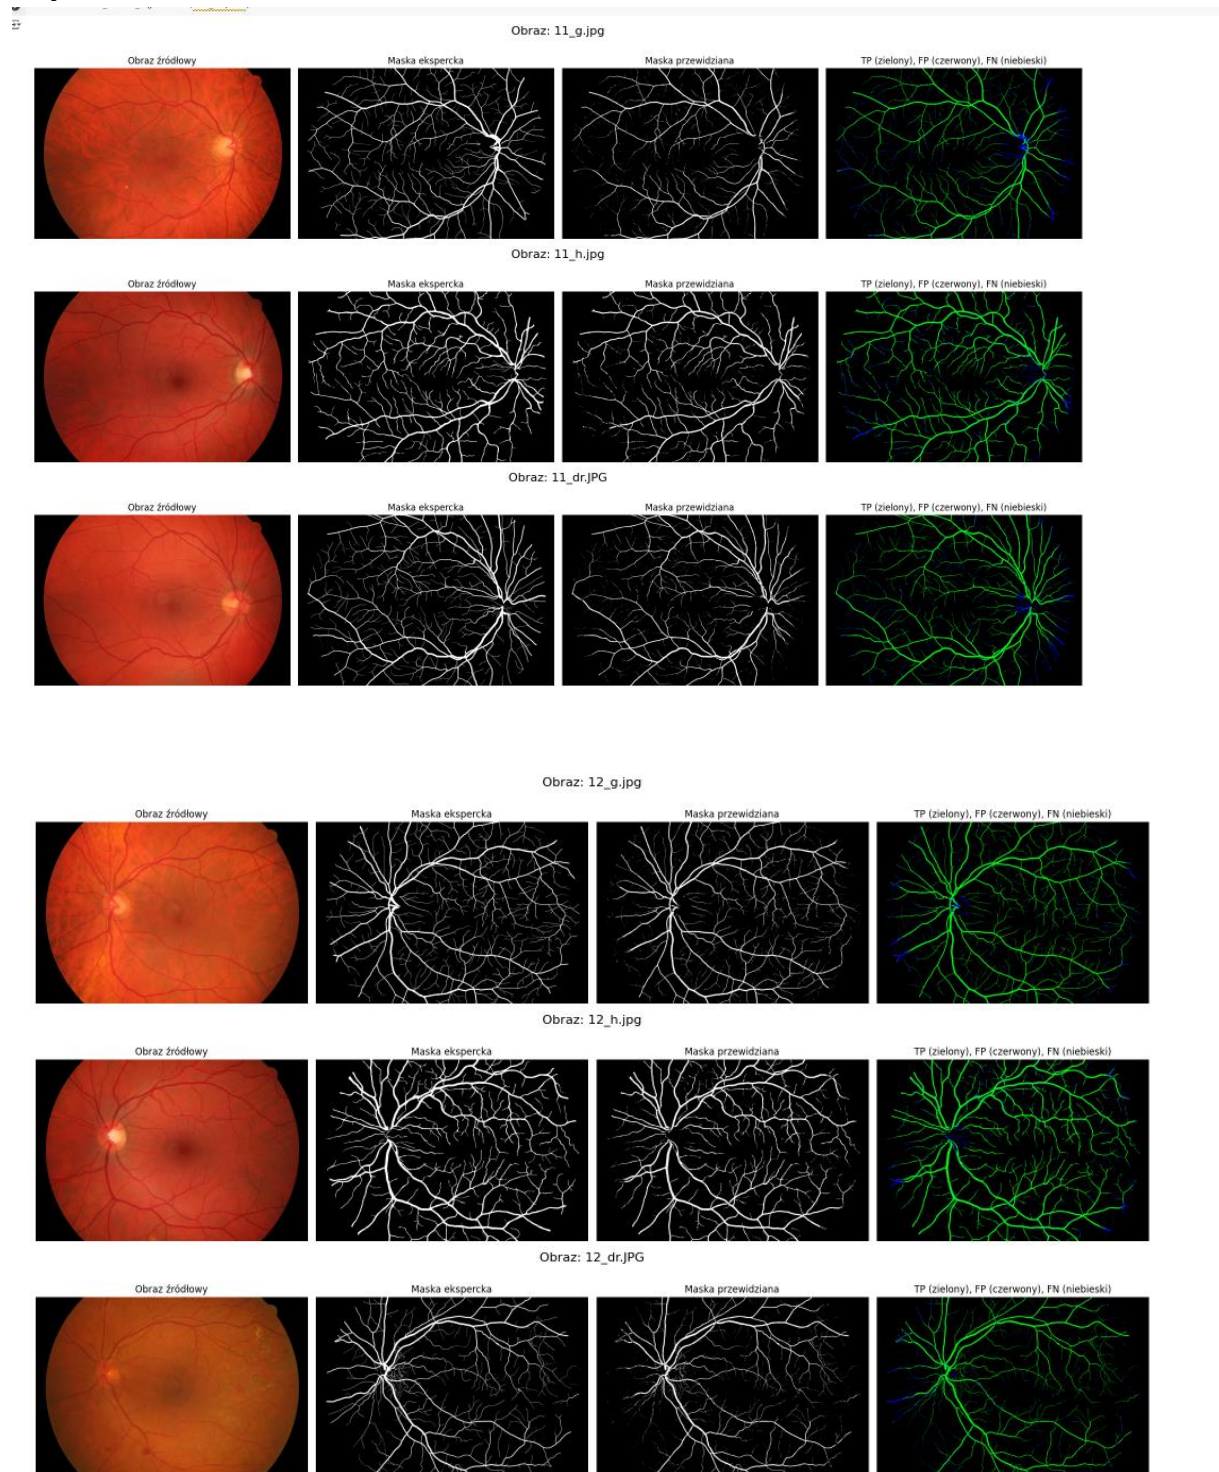
## 3. Opis zastosowanych metod

### 3.1 Przetwarzanie obrazów

- **Kanał zielony:** ekstrakcja informacji strukturalnej (naczynia najlepiej widoczne).
- **Denoising (FastNIMeansDenoising):** redukcja szumów bez utraty szczegółów.
- **Equalizacja histogramu:** wzmocnienie kontrastu naczyń.
- **Filtr Frangiiego:** wykrywanie naczyń.
- **Progowanie:** ręczne progowanie odpowiednio dobrane eksperymentalnie.
- **Postprocessing:** usunięcie drobnych obiektów, zamknięcie morfologiczne.
- **Maskowanie FOV:** ograniczenie segmentacji do wnętrza siatkówki.

**Uzasadnienie:** Do analizy naczyń krwionośnych zastosowaliśmy klasyczne metody przetwarzania obrazu, skupiając się na poprawie kontrastu i redukcji szumu. Wybrano kanał zielony, ponieważ najlepiej uwidacznia naczynia na tle siatkówki. Filtr FastNIMeansDenoising usunął szum bez rozmywania cienkich struktur, a equalizacja histogramu zwiększyła kontrast naczyń względem tła. Zastosowana dylacja pozwoliła wzmocnić słabo widoczne naczynia przed dalszą segmentacją. Tak przygotowane obrazy były lepiej przystosowane do działania filtru Frangiiego i progowania.

## Wyniki Przetwarzania



## Miary dla klasycznego podejścia

	accuracy	sensitivity	specificity	harmonic_mean	arithmetic_mean	TP	TN	FP	FN	image
0	0.7241	0.7241	0	0.0	0.3621	453077	0	0	172616	11_g.jpg
1	0.8105	0.8105	0	0.0	0.4053	620346	0	0	145009	11_h.jpg
2	0.7908	0.7908	0	0.0	0.3954	547969	0	0	144968	11_dr.JPG
3	0.8445	0.8445	0	0.0	0.4223	571271	0	0	105153	12_g.jpg
4	0.8527	0.8527	0	0.0	0.4264	732763	0	0	126532	12_h.jpg
5	0.8325	0.8325	0	0.0	0.4162	463446	0	0	93278	12_dr.JPG

### 3.2 Uczenie maszynowe *Decision Tree Classifier*

W podejściu opartym na uczeniu maszynowym segmentujemy obrazy siatkówki na małe fragmenty (patches) o stałym rozmiarze, np. 15×15 pikseli. Dla każdego takiego fragmentu obliczamy zestaw cech opisujących jego strukturę i teksturę – są to momenty  $H_u$  (odporne na rotacje i skalowanie) oraz wariancje jasności w kanałach RGB. Cechy te reprezentują właściwości wizualne naczyń krwionośnych i stanowią wejście dla klasyfikatora.

Maska ekspercka (ground truth) jest dzielona na te same fragmenty i wykorzystywana do oznaczenia każdego segmentu jako naczyniowy (1) lub tło (0), zależnie od wartości środkowego piksela. Z uwagi na dużą nierównowagę klas (dużo więcej tła niż naczyń), stosujemy *undersampling*, by zrównoważyć liczbę przykładów obu klas w zbiorze treningowym.

Do klasyfikacji zastosowano model drzewa decyzyjnego `DecisionTreeClassifier` z biblioteki `scikit-learn`. W celu kontroli złożoności modelu i uniknięcia przeuczenia przyjęto następujące parametry:

- `max_depth=30` – maksymalna głębokość drzewa została ograniczona do 30 poziomów, co pozwala modelowi uchwycić złożone zależności, ale zapobiega nadmiernemu dopasowaniu do szumu w danych;
- `min_samples_leaf=5` – minimalna liczba próbek w liściu ustalona na 5 sprawia, że drzewo nie tworzy zbyt małych i niestabilnych reguł;
- `random_state=42` – ustalono stały seed dla zapewnienia powtarzalności wyników;
- użyto domyślnego algorytmu podziału i funkcji entropii

Model uczony jest na przygotowanych cechach wyciągniętych z obrazu `01_dr.JPG`, który nie pojawia się w zbiorze testowym.

W trakcie predykcji każdy fragment nowego obrazu jest klasyfikowany przez wytrenowany model. Jeśli prawdopodobieństwo klasy "naczynie" przekracza ustalony próg, to cały segment jest oznaczany jako naczyniowy w masce wynikowej. W ten sposób tworzymy binarną maskę wykrytych naczyń krwionośnych.




## Wyniki Klasyfikatora

# Predykcja na obrazie: 11\_g  
Segmentów wykrytych jako naczyń: 7849


Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)



TP/FP/FN (zielony/czerwony/niebieski)




# Predykcja na obrazie: 11\_h  
Segmentów wykrytych jako naczyń: 11374


Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)




TP/FP/FN (zielony/czerwony/niebieski)




# Predykcja na obrazie: 11\_dr  
Segmentów wykrytych jako naczyń: 9518


Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)




TP/FP/FN (zielony/czerwony/niebieski)




# Predykcja na obrazie: 12\_g  
Segmentów wykrytych jako naczyń: 8467


Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)




TP/FP/FN (zielony/czerwony/niebieski)




# Predykcja na obrazie: 12\_h  
Segmentów wykrytych jako naczyń: 12810


Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)



TP/FP/FN (zielony/czerwony/niebieski)




# Predykcja na obrazie: 12\_dr  
Segmentów wykrytych jako naczyń: 9897

Obraz źródłowy




Maska ekspercka



Maska RF (proba > threshold)



TP/FP/FN (zielony/czerwony/niebieski)



	accuracy	sensitivity	specificity	harmonic_mean	arithmetic_mean	TP \
0	0.814826	0.710321	0.823476	0.762724	0.766898	444443
1	0.750783	0.851661	0.740378	0.792129	0.796019	651823
2	0.782440	0.772744	0.783337	0.778004	0.778040	535463
3	0.802400	0.722965	0.809555	0.763813	0.766260	489031
4	0.723042	0.869954	0.705810	0.779332	0.787882	747547
5	0.777786	0.717668	0.782174	0.748533	0.749921	399543

	TN	FP	FN	image
0	6225188	1334463	181250	11_g
1	5493593	1926396	113532	11_h
2	5869078	1623329	157474	11_dr
3	6078886	1430034	187393	12_g
4	5170798	2155251	111748	12_h
5	5966905	1661715	157181	12_dr

Model drzewa decyzyjnego osiągnął dobre i stabilne wyniki — accuracy utrzymywało się w granicach 77–81%, a czułość (sensitivity) nawet powyżej 0.85, co oznacza skuteczne wykrywanie naczyń krwionośnych. Wyniki były zrównoważone, a harmoniczna średnia sięgała 0.79, co świadczy o dobrym kompromisie między wykrywaniem naczyń a unikaniem fałszywych alarmów.

Zastosowaliśmy drzewo decyzyjne, ponieważ jest szybkie, dobrze radzi sobie z nieliniowymi zależnościami, pozwala kontrolować złożoność modelu i jest łatwe do interpretacji. To sprawia, że dobrze sprawdza się w zadaniach klasyfikacji segmentów obrazu.

### 3.3 Sieć neuronowa


W celu dokładniejszego rozpoznawania drobnych struktur naczyń zastosowano segmentacyjną sieć neuronową U-Net, która sprawdza się w zadaniach segmentacji medycznej. Obrazy wejściowe były wcześniej przetwarzane – wykorzystywano tylko kanał zielony, który został poddany denoisingowi, dylacji i equalizacji histogramu, aby zwiększyć kontrast naczyń. Dla poprawy równowagi klas sieć uczona była na zbalansowanych fragmentach obrazu (patchach 128×128 px), zawierających jednocześnie naczynia i tło.


Maski eksperckie oraz obrazy były ograniczane przez FOV, dzięki czemu sieć nie uczyła się na czarnych obszarach spoza siatkówki. Model U-Net zawiera cztery poziomy enkodera i dekodera, z dodatkowymi warstwami konwolucyjnymi i transpozycyjnymi, oraz funkcję aktywacji sigmoid na wyjściu. Trenowano go przez 40 epok z użyciem funkcji kosztu będącej sumą **Binary Cross Entropy** i **Dice loss**, co pozwalało lepiej wyważyć wpływ zarówno obszarów tła, jak i naczyń. Zastosowany optymalizator to Adam z krokiem uczenia 1e-4.

To podejście pozwoliło sieci skutecznie uczyć kształtu i rozmieszczenia naczyń krwionośnych na podstawie lokalnego kontekstu i struktury obrazu.



## Wyniki przetwarzania





	accuracy	sensitivity	specificity	harmonic_mean	arithmetic_mean	TP	TN	FP	FN	image
0	0.9567	0.6879	0.9830	0.8094	0.8355	16086	234714	4047	7297	11_g.jpg
1	0.9656	0.7658	0.9889	0.8632	0.8773	20909	232228	2613	6394	11_h.jpg
2	0.9545	0.7014	0.9819	0.8183	0.8417	17938	232289	4281	7636	11_dr.JPG
3	0.9515	0.7403	0.9740	0.8412	0.8571	18686	230741	6162	6555	12_g.jpg
4	0.9635	0.7514	0.9913	0.8548	0.8713	22807	229764	2027	7546	12_h.jpg
5	0.9534	0.6504	0.9797	0.7818	0.8151	13612	236322	4894	7316	12_dr.JPG

## 4. Porównanie Wyników Drzewa i Sieci

Sieć neuronowa U-Net osiągnęła bardzo dobre wyniki — **accuracy na poziomie 95–96%**, przy **high specificity (do 99%)** oraz zauważalnej poprawie równowagi między czułością a precyzją.

**Harmoniczna średnia (łącząca sensitivity i specificity)** wynosiła od **0.78 do 0.86**, co oznacza skuteczne i zrównoważone wykrywanie naczyń.

W porównaniu z wcześniejszym klasyfikatorem drzewa decyzyjnego, U-Net:

- **zdecydowanie lepiej** radził sobie z odróżnianiem naczyń od tła (wyższa *specificity*),
- utrzymał **porównywalną lub lepszą czułość** (*sensitivity* do 0.76),
- i znacząco **zmniejszył liczbę fałszywych pozytywów (FP)** oraz fałszywych negatywów (FN).

Model uczył się na wycinkach obrazów, ale potrafił skutecznie generalizować wiedzę na całe obrazy testowe. U-Net lepiej odwzorowywał strukturę naczyń, zwłaszcza cienkich i lokalnie słabo widocznych, co klasyfikator oparty na patchach często pomijał. W praktyce oznacza to, że sieć neuronowa zapewnia bardziej spójne i dokładne segmentacje w zastosowaniach medycznych.

